

《通信原理》课程复现研究报告

无蜂窝大规模 MIMO 系统中基于学习的下行链路功率分配

学生姓名: 范立霖

学 号: 21312748

院 系: 网络空间安全学院

专 业: 网络空间安全专业

时间: 二〇二三年十二月二十日

摘要

本文主要对基于学习的下行链路功率分配这个领域进行学习，并复现了论文 *Learning-Based Downlink Power Allocation in Cell-Free Massive MIMO Systems* 进行效果观察。该论文考虑了一种无蜂窝的大规模多输入多输出 (MIMO) 系统，该系统由大量地理分布的接入点 (AP) 组成，通过相干联合传输为多个用户提供服务。文章凭借最大比率和正则化迫零预编码的操作，以功率分配的两个优化目标：总和频谱效率 (sum-SE) 最大化和比例公平，来评估系统的下行链路性能。为了实现计算复杂度较低且可分布扩展的解决方案，论文作者还训练了一个深度神经网络 (DNN)，以近似网络范围的功率分配。文章作者没有训练 DNN 来模拟实际的优化过程，而是使用基于大规模衰落 (LSF) 参数的启发式功率分配作为 DNN 的预处理输入。不过调整了 DNN 来优化启发式方案，从而在每个 AP 上仅使用本地信息提供更高的 SE。为了提高性能，论文作者还设计了另一个能够利用中央处理单元的额外信息的分布式 DNN。此外，文章作者开发了一个聚类 DNN 模型，其中少量 AP 的 LSF 参数，在相对较大的网络中形成集群，用于联合逼近集群的功率系数。

关键词： 无蜂窝大规模 MIMO，功率分配，sumSE 最大化，比例公平，深度学习，频谱效率，下行链路。

目录

第 1 章	引言	1
1.1	选题背景与意义	1
1.2	国内外研究现状和相关工作	1
1.3	复现论文的研究内容与主要贡献	2
1.4	文章结构与章节安排	2
第 2 章	基本原理	4
2.1	信道估计	4
2.2	导频分配	4
2.3	下行数据传输	5
2.4	WMMSE 算法	6
2.5	本章小结	7
第 3 章	系统原理	8
3.1	sum-SE 和 PF 最大化功率分配	8
3.2	分布式 DNN 功率分配	11
3.3	聚类 DNN 功率分配	13
3.4	训练	14
3.5	本章小结	17
第 4 章	结果分析	18
4.1	模拟设置	18
4.2	Sum-SE 与 PF 最大化	19
4.3	有额外信息的 DDNN	20
4.4	CDNN	21
4.5	本章小结	22
第 5 章	总结	23
5.1	工作总结	23
5.2	研究展望	23
	参考文献	24

第 1 章 引言

1.1 选题背景与意义

无线通信流量的不断增长使得每一代新的蜂窝网络技术都必须寻找新的方法来实现更多设备的复用并增加每个设备的频谱效率。5G 的核心技术是大规模多输入多输出 (MIMO)，其中每个接入点 (AP) 都配备了大量的活动天线，以在相同的时频资源上对大量用户设备 (UE) 进行空间复用。在超越 5G 的技术中，无蜂窝大规模 MIMO 是一种新兴的后蜂窝基础架构，旨在重建无线网络以提供普遍连接性。其关键特点是大量分布式 AP 共同为给定覆盖区域内的 UE 提供服务，而不会创建人为的蜂窝边界。这可以改善网络连接性和能源效率。无蜂窝大规模 MIMO 可能成为超越 5G 技术的基础，因为它能够利用宏观多样性和多用户干扰抑制来为 UE 提供几乎同等的服务质量。

1.2 国内外研究现状和相关工作

构建无蜂窝网络基础设施的主要挑战是信号处理的计算复杂性和 AP 之间信息交换的巨大前传需求。因此，人们希望建立网络时使用有限容量的前传链路连接 AP 和中央处理单元 (CPU)。在 MIMO 系统中，分散方案已经在 [20], [21] 中进行了研究，这些方案可以扩展到无蜂窝系统。最近的研究 [10], [12], [22] 侧重于网络规模扩大时各种算法的可扩展性方面。由于不同的 UE 同时在相同的时频资源上进行服务，功率分配在限制多用户干扰和优化整个网络性能方面起着重要作用。[5], [24] 注意到网络级下行 (DL) 最大最小公平性问题是准凸的，并且作者使用通用求解器解决了这个问题。[9] 中开发了更高效的专用算法，用于网络级 DL 最大最小公平性和总 SE 最大化。然而，这些算法的计算复杂度随着 AP 和 UE 的数量呈多项式增长，导致不可扩展的解决方案，可能违反实时处理约束。

解决功率分配问题的另一种方法是采用“学习优化”方法，利用深度神经网络 (DNN) 可以学习丰富的模式和近似复杂函数映射的特点。与传统方法相比，这可以显著降低计算复杂度，从而实现实时可实现的解决方案。需要付出的代价是在 DNN 投入运行之前需要进行广泛的训练，但这不构成问题，因为训练是离线进行的。在蜂窝大规模 MIMO 的背景下，[28] 中的作者训练了一个前馈 DNN，该 DNN 使用确切的 UE 位置作为输入来学习最大最小公平性和比例公平性 (PF) 下的最

功率系数，而 [31] 则开发了一个 DNN，用于联合导频和数据功率控制，以实现上行链路的 sum-SE 最大化。在 [23] 中，设计了一个集中式深度卷积神经网络，用于近似无蜂窝大规模 MIMO DL 中的最大最小公平性目标的功率系数。此外，[18] 还针对无蜂窝系统上行链路的总 SE 最大化，考虑了 AP 和 CPU 之间的有限容量前传链路，开发了另一种集中式深度学习解决方案。在 [29] 中，开发了用于小型无蜂窝大规模 MIMO 设置中最大最小公平功率分配的集中式和分布式 DNN。大规模衰落（LSF）系数被用作集中式和分布式 DNN 实现的输入。特别是在分布式情况下，结果表明近似性能不令人满意，可能是由于两个主要因素：1) 输入未基于先前领域知识进行预处理，以确定功率分配所需的关键信息；2) DNN 未近似估计每个 AP 的总发射功率，在分布式情况下这是必不可少的。

1.3 复现论文的研究内容与主要贡献

论文作者提出了一种完全分布式的前馈深度神经网络（DNN）模型，仅利用 AP 本地可用的信息作为输入，去近似计算每个接入点（AP）的归一化功率系数和总发射功率。在训练阶段，利用网络范围内的频谱效率（SE）和比例公平性（PF）解作为标签输出。每个 AP 都可以使用 DNN 这个基本的网络结构隐式地学习到传播环境。然后再采用启发式的封闭式功率分配方法，将 AP 与用户设备（UE）之间的 LSF 系数，用作 DNN 的输入。除此之外，启发式的输入也能起到提供更好的输入数据缩放的作用，使 DNN 模型的输入/输出关系变得更加简单。

论文作者还开发了另一个分布式 DNN，其利用辅助信息，即给定 AP 的 LSF 系数与网络中所有 AP 的 LSF 系数之比，以增强基于学习的功率分配的性能。此外，作者还提出了一种聚类 DNN 模型，其将相对较大网络中形成了一个集群的少数 AP 的 LSF 参数输入到 DNN 中，以同时学习集群的“最优”功率分配。与分布式解决方案相比，该体系结构在性能上更好，但对前向链路的要求有所提高。

论文作者对其所提出的 DNN 模型进行了复杂度分析，并与传统的功率分配优化方法进行了对比。

1.4 文章结构与章节安排

本文共分为五章，各章节内容安排如下：

1.4.1 第一章引言

本章节主要介绍了选题的背景与意义、介绍了国内外研究现状与相关工作、介绍了复现论文的研究内容与主要贡献、阐述了本文的文章结构和章节安排。

1.4.2 第二章基本原理

本章节主要对论文所使用的概念、指标和方法进行了简单介绍。

1.4.3 第三章系统原理

在本章中将对系统的原理进行详细介绍，包括 sum-SE 和 PF 最大化功率分配方法、分布式 DNN 功率分配模型、聚类 DNN 功率分配模型、训练详情。

1.4.4 第四章

在本章节中对论文进行复现，展示结果并分析。

1.4.5 第五章

总结与展望。

第 2 章 基本原理

在本章中主要对论文所使用的概念、指标和方法进行简单介绍，在第 3 章系统原理中将结合步骤进行详细介绍。

2.1 信道估计

本文考虑了一个时分双工（TDD）协议，包括用于信道估计的导频传输阶段和数据传输阶段。根据文献 [2]，相干块被分为三个部分：用于上行导频的 τ_u 个样本，用于上行数据传输的 τ_p 个样本，以及用于下行数据传输的 τ_d 个样本。因此，本文有 $\tau_c = \tau_p + \tau_u + \tau_d$ 。由于本文侧重于下行功率分配，只考虑了上行导频和下行数据传输，所以 $\tau_u = 0$ 。

在信道估计阶段，每个用户设备（UE）被分配一个随机的长度为 τ_p 的导频，该导频来自接入点（AP）使用的 τ_p 个互相正交的导频集合。令 $t_k \in \{1, \dots, \tau_p\}$ 表示分配给 UE k 的导频的索引。在将 AP 1 接收到的信号与导频 t_k 进行关联以估计 UE k 的信道后，得到了信号 $\mathbf{y}_{t_k l}^p \in \mathbb{C}^{N \times 1}$ 为

$$\mathbf{y}_{t_k l}^p = \sum_{\substack{i=1 \\ t_i=t_k}}^K \sqrt{\tau_p p_i} \mathbf{h}_{il} + \mathbf{n}_{t_k l} \quad (2.1)$$

2.2 导频分配

为了使 UE 能够接入网络，需要将其分配到一个导频序列中。而为了便于集中研究功率分配问题，采用了来自文献 [10] 的低复杂度分配算法，其中前 τ_p 个 UE 被分配了正交的导频。剩下的 UE 按照以下方式分配导频：UE k ,

$$k = \tau_p + 1, \dots, K: \quad (2.2)$$

步骤 1: UE 确定信号最强的 AP，并将其指定为自己的主 AP。这个 AP 的索引由以下公式给出。

$$l^* = \arg \max_{l \in \{1, \dots, L\}} \beta_{kl} \quad (2.3)$$

步骤 2: 主 AP 确定第 $k-1$ 个已经分配了导频的 UE 的各自导频干扰最小的导频索引。将该导频分配给 UE k , 然后算法继续处理下一个 UE。

$$\tau = \arg \min_{t \in \{1, \dots, \tau_p\}} \sum_{\substack{i=1 \\ t_i=t}}^{k-1} \beta_{il}^*. \quad (2.4)$$

简而言之, 每个 UE 按序分配到具有最少导频干扰的导频序列中。该算法能够有效避免最坏情况下两个 UE 被分配到同一个导频的情况。这减少了在 UE 具有相似的 LSF 配置的情况下, 神经网络训练数据集中的歧义, 尽管导频分配会导致信道估计的精度不同。

2.3 下行数据传输

假设所有的 UE 都在相同的时频资源上由所有的 L 个 AP 提供服务。因此, UE k 接收到的下行信号可以表示为:

$$y_k^{dl} = \sum_{l=1}^L \mathbf{h}_{kl}^H \sum_{i=1}^K \sqrt{\rho_{il}} \mathbf{w}_{il} s_i + n_k, \quad (2.5)$$

其中 $\rho_{il} \geq 0$ 是 AP l 分配给 UE i 的下行功率, $\mathbf{w}_{il} \in \mathbb{C}^{N \times 1}$ 是相应的归一化预编码向量, 满足 $\|\mathbf{w}_{il}\|^2 = 1$ 。此外, s_i 表示用于 UE i 的零均值信号, $n_k \sim \mathcal{N}_{\mathbb{C}}(0, \sigma^2)$ 表示 UE k 处的噪声。以下引理给出了无蜂窝系统中遍历 DL SE 的下界。

Lemma 1 [9, Lem. 1] UE k 的可实现的 SE 下界由以下公式给定:

$$\text{SE}_k = \frac{\tau_d}{\tau_c} \log_2 (1 + \text{SINR}_k) \quad (2.6)$$

其中

$$\text{SINR}_k = \frac{(\mathbf{a}_k^T \boldsymbol{\mu}_k)^2}{\sum_{i=1}^K \mu_i^T \mathbf{B}_{ki} \mu_i - (\mathbf{a}_k^T \boldsymbol{\mu}_k)^2 + \sigma^2} \quad (2.7)$$

表示有效的 SINR, 同时

$$\boldsymbol{\mu}_k = [\mu_{k1} \cdots \mu_{kL}]^T \in \mathbb{R}^{L \times 1}, \mu_{kl} = \sqrt{\rho_{kl}} \quad (2.8)$$

$$\mathbf{a}_k = [a_{k1} \cdots a_{kL}]^T \in \mathbb{R}^{L \times 1}, a_{kl} = \mathbb{E} \{ \mathbf{h}_{kl}^H \mathbf{w}_{kl} \} \quad (2.9)$$

$$\mathbf{B}_{ki} \in \mathbb{R}^{L \times L}, b_{ki}^{lm} = \Re(\mathbb{E}\{\mathbf{h}_{kl}^H \mathbf{w}_{il} \mathbf{w}_{im}^H \mathbf{h}_{km}\}) \quad (2.10)$$

在 (2.7) 中, $\mathbf{a}_k^T \mu_k$ 对应于 UE k 在确定性预编码信道上的期望信号增益。该谱效率表达式适用于任何预编码方案, 其中预编码向量旋转使得 $a_{kl} = \mathbb{E}\{\mathbf{h}_{kl}^H \mathbf{w}_{kl}\}$ 为非负实数, 并且考虑了相关的瑞利衰落模型。所考虑的预编码向量 $\{\mathbf{w}_{il}\}$ 满足短期功率约束, 即在每个相干块中满足 $\|\mathbf{w}_{il}\|^2 = 1$, 而不是平均值。在无蜂窝大规模 MIMO 系统中, 放宽这个条件, 例如 $\mathbb{E}\{\|\mathbf{w}_{il}\|^2\} = 1$ 不是可取的, 因为少量天线的 AP 与 UE 之间的信道不会变得更加稳定 [29]。归一化的预编码向量定义为 $\mathbf{w}_{il} = \bar{\mathbf{w}}_{il} / \|\bar{\mathbf{w}}_{il}\|$, 其中 $\bar{\mathbf{w}}_{il}$ 可以任意选择。本文的主要贡献适用于任何预编码方案。不过, 在数值评估中, 本文将采用最大比 (MR) 和正则化零强迫 (RZF) 预编码方案, 其定义为

$$\bar{\mathbf{w}}_{kl} = \begin{cases} \hat{\mathbf{h}}_{kl} & \text{for MR,} \\ \left(\sum_{i=1}^K p_i \hat{\mathbf{h}}_{il} \hat{\mathbf{h}}_{il}^H + \sigma^2 \mathbf{I}_N \right)^{-1} p_k \hat{\mathbf{h}}_{kl} & \text{for RZF.} \end{cases} \quad (2.11)$$

2.4 WMMSE 算法

网络范围的总和频谱效率 (sum-SE) 和基于比例公平性 (PF) 的功率分配优化问题都是非凸优化问题, 需要找到最优的功率分配策略。

加权最小均方误差 (WMMSE) 算法: 为了解决这些非凸优化问题, 论文采用了加权最小均方误差 (WMMSE) 算法。这个算法受到了之前工作的启发, 并被应用于求解 WMMSE 算法中的二次约束二次子问题。为了高效地求解这些子问题, 论文采用了交替方向乘子法 (ADMM) 的方法。

WMMSE 算法步骤如下:

输入: 初始化待优化变量 $\mu_{kl}^{(0)}, \forall k, l$. 设置迭代索引 $n \leftarrow 0$ 和解精度 $\epsilon_{\text{WMMSE}} > 0$.

1: 重复

2: 更新变量 $v_k^{(n+1)}, k = 1, \dots, K$ 为

$$v_k^{(n+1)} = \frac{\mathbf{a}_k^T \mu_k^{(n)}}{\sum_{i=1}^K \left(\mu_i^{(n)} \right)^T \mathbf{B}_{ki} \mu_i^{(n)} + \sigma^2}. \quad (2.12)$$

3: 更新变量 $e_k^{(n+1)}, k = 1, \dots, K$ 为

$$e_k^{(n+1)} = 1 - \frac{\left(\mathbf{a}_k^T \mu_k^{(n)}\right)^2}{\sum_{i=1}^K \left(\mu_i^{(n)}\right)^T \mathbf{B}_{ki} \mu_i^{(n)} + \sigma^2}. \quad (2.13)$$

4: 更新变量 $\omega_k^{(n+1)}, k = 1, \dots, K$ 为

如果是 sum-SE 最大化:

$$\omega_k^{(n+1)} = 1 / e_k^{(n+1)}, \quad (2.14)$$

如果是 PF 最大化:

$$\omega_k^{(n+1)} = -1 / \left(e_k^{(n+1)} \ln \left(e_k^{(n+1)} \right) \right). \quad (2.15)$$

5: 更新 $\left\{ \mu_{kl}^{(n+1)} : \forall k, l \right\}$ 作为问题的解

$$\begin{aligned} & \underset{\{\mu_{kl} : \forall k, l\}}{\text{minimize}} \quad \sum_{k=1}^K \omega_k^{(n+1)} \left[\left(v_k^{(n+1)} \right)^2 \right. \\ & \quad \times \left. \left(\sum_{i=1}^K \mu_i^T \mathbf{B}_{ki} \mu_i + \sigma^2 \right) - 2 v_k^{(n+1)} \mathbf{a}_k^T \mu_k + 1 \right] \\ & \text{subject to} = \sum_{k=1}^K \mu_{kl}^2 \leq P_{\max}^{\text{dl}}, \quad l = 1, \dots, L. \end{aligned} \quad (2.16)$$

6: 赋值 $\mathbf{n} \leftarrow \mathbf{n} + 1$

7: 直到当前和上一次迭代的目标函数之差的平方小于 ϵ_{WMMSE}

输出: 局部最优: μ_{kl}^*

2.5 本章小结

本章对论文所使用的概念、指标和方法进行了简单介绍, 在第 3 章系统原理中将结合步骤进行详细介绍。

第3章 系统原理

在本章中将对系统的原理进行详细介绍，包括 sum-SE 和 PF 最大化功率分配方法、分布式 DNN 功率分配模型、聚类 DNN 功率分配模型、训练详情。

3.1 sum-SE 和 PF 最大化功率分配

在这一部分中，本文讨论求解最大化总和谱效率（Sum Spectral Efficiency）和比例公平性（Proportional Fairness）的功率分配问题。目标是在相同的每个 AP（接入点）功率约束下找到一组 DL（下行链路）的功率分配系数 $\rho_{kl} : \forall k, l$ ，能够最大化总和谱效率或产品谱效率（在比例公平性的情况下）。功率约束表示为

$$\sum_{k=1}^K \rho_{kl} \leq P_{\max}^{\text{dl}}, \quad l = 1, \dots, L, \quad (3.1)$$

其中 P_{\max}^{dl} 是每个 AP 允许的最大传输功率。为了揭示隐藏的问题结构，本文使用（2.8）中的变量 μ_{kl} 来表达这两个问题，这些变量是功率分配系数 ρ_{kl} 的平方根。由于这些变量仅出现在二次形式中，本文在考虑的优化问题中没有包括 $\mu_{kl} \geq 0$ 的约束（类似于 [2.9]），因为这样可以得到结果算法中的闭式更新方程。这种做法不会导致任何问题，因为优化算法结束时，任何负的 μ_{kl} 的符号都可以被正的对应项替换，而不会使任何其他约束失效。

3.1.1 sum-SE 最大化

通过移除（2.6）中的常数预处理因子，总谱功率最大化的功率分配问题可以表示为

$$\begin{aligned} & \underset{\{\mu_{kl} : \forall k, l\}}{\text{maximize}} && \sum_{k=1}^K \log_2(1 + \text{SINR}_k) \\ & \text{subject to} && \sum_{k=1}^K \mu_{kl}^2 \leq P_{\max}^{\text{dl}}, \quad l = 1, \dots, L. \end{aligned} \quad (3.2)$$

该问题是非凸的，并且找到全局最优解非常复杂。在本文中，本文将使用 WMMSE 算法通过高效的迭代算法获得局部最优解，这对于用该算法生成大规

模的训练数据集非常重要。本文采用类似于 [28] 的蒙特卡罗方法来计算最优功率。为了完整起见，算法 1 概述了算法的主要步骤。请注意，除了第 4 步之外，算法的所有步骤在总谱效率和 PF 问题中是相同的；因此，本文在算法 1 中同时呈现它们。上标 (n) 表示迭代 n 时的值。算法 1 中的辅助变量 $v_k^{(n)}$, $e_k^{(n)}$, and $\omega_k^{(n)}$ 来自于 WMMSE 改进 [9]、[35]、[36]。算法中第 5 步的子优化问题是一个凸二次约束二次规划问题，可以使用 [9, Alg. 1] 中的闭式 ADMM 算法来求解。

3.1.2 PF 最大化

前面部分考虑的总谱功率最大化问题并未考虑 UE 之间的公平性。实际上，更多的重点放在网络中相对幸运的 UE 上，以最大化总谱效率。与总谱效率不同，PF (Proportional Fairness) [36]–[38] 是一种替代的效用函数，可以表示为 UE 个体谱效率的对数之和。PF 最大化在最大最小公平性和总谱效率之间取得了良好的平衡，它通过关注信道条件最差的 UE 来限制网络整体性能。相应的优化问题可以表示为：

$$\begin{aligned} & \underset{\{\mu_{kl} : \forall k, l\}}{\text{maximize}} && \sum_{k=1}^K \ln(\log_2(1 + \text{SINR}_k)) \\ & \text{subject to} && \sum_{k=1}^K \mu_{kl}^2 \leq P_{\max}^{\text{dl}}, \quad l = 1, \dots, L. \end{aligned} \quad (3.3)$$

在上述公式中，常数预处理因子被省略，因为它们不影响优化问题。与总谱效率最大化问题类似，PF 问题也是非凸的，很难以合理的复杂度获得全局最优解。PF 最大化的问题结构需要进行不同的改进，以获得由 WMMSE 算法引入的辅助变量的闭式更新。首先，通过将接收权重 v_k 应用于 UE k，可以获得数据符号的估计值，如下所示：

$$\hat{s}_k = v_k y_k^{\text{dl}} = v_k \sum_{l=1}^L \mathbf{h}_{kl}^H \sum_{i=1}^K \sqrt{\rho_{il}} \mathbf{w}_{il} s_i + v_k n_k. \quad (3.4)$$

然后，将均方误差 (MSE) 定义为

$$\begin{aligned} e_k &= \mathbb{E} \{ |\hat{s}_k - s_k|^2 \} \\ &= v_k^2 \left(\sum_{i=1}^K \mu_i^T \mathbf{B}_{ki} \mu_i + \sigma^2 \right) - 2v_k \mathbf{a}_k^T \mu_k + 1, \end{aligned} \quad (3.5)$$

本文可以将 (3.4) 中的问题重新表述为

$$\begin{aligned}
 & \underset{\substack{\{\mu_{kl} : \forall k, l\} \\ \{\omega_k \geq 0, v_k : \forall k\}}}{\text{maximize}} && \sum_{k=1}^K (\omega_k e_k + f(g(\omega_k)) - \omega_k g(\omega_k)) \\
 & \text{subject to} && \sum_{k=1}^K \mu_{kl}^2 \leq P_{\max}^{\text{dl}}, \quad l = 1, \dots, L.
 \end{aligned} \tag{3.6}$$

函数 $f(x)$ 定义为 $f(x) = -\ln(-\ln(x))$ ，对于 $0 < x < 1$ 。其导数可以写成 $f'(x) = -1/(x \ln(x))$ ，对于 x 的定义范围为正数。函数 $g(x)$ 是 $f'(x)$ 的逆函数，即 $f'(g(x)) = x$ 。

问题 (3.3) 和 (3.6) 在具有相同全局最优解方面的等价性源于以下事实：通过将问题 (3.6) 中目标函数的导数置零，可以得到最优解 ω_k

$$e_k + f'(g(\omega_k)) g'(\omega_k) - g(\omega_k) - \omega_k g'(\omega_k) = 0. \tag{3.7}$$

由于 $f'(g(\omega_k)) = \omega_k$ ，本文有 $e_k = g(\omega_k)$ ，因此 $\omega_k^{\text{opt}} = f'(e_k)$ 。将 ω_k^{opt} 代入 (3.6) 中的目标，得到

$$\sum_{k=1}^K (f'(e_k) e_k + f(g(f'(e_k))) - f'(e_k) g(f'(e_k))) \tag{3.8}$$

因为本文有 $g(f'(e_k)) = f'(g(e_k)) = e_k$ ，并且由于均方误差 e_k 的表达式不依赖于所选择的效用函数，辅助变量 $v(n)_k$ 和 $e(n)_k$ 的更新与前面提到的 sum-SE 最大化中的相同，因此 (3.8) 给出

$$\sum_{k=1}^K f(e_k) = \sum_{k=1}^K -\ln(-\ln(e_k)) = -\sum_{k=1}^K \ln(\ln(1 + \text{SINR}_k)) \tag{3.9}$$

因此，最小化 (3.6) 中的目标函数与最大化 (3.3) 中的目标函数是相同的。通过修改 (2.15) 中辅助变量 $(n+1)_k$ 的更新方式（该更新方式是从 [36, The. 2] 中推导得到的），本文可以使用算法 1 和 ADMM 方法得到 PF 最大化问题的局部最优解。对于机器学习算法，通过解决求和 SE 和 PF 最大化问题来生成训练数据。为了管理大规模设置，本文需要合理低的计算复杂度，这得益于 WMMSE-ADMM 算法的闭合形式更新。对于给定的设置，可以使用其他效用函数，例如，在相同的优化目标中加入权重是直接的。然而，所选择的求和 SE 和 PF 最大化方案已经涵盖了基于 SE 最大化的移动网络功率分配的实际选择。

3.2 分布式 DNN 功率分配

在前一节中描述的优化算法中，每个算法都通过使用网络范围的信息最大化了网络性能目标，必须在 CPU 上实现。本文的主要目标之一是开发分布式算法，这些算法可以基于本地可用信息在每个接入点（AP）上分别实现，同时仍旧旨在最大化网络范围的性能目标。在本节中，本文以分布式 DNN 的形式开发基于学习的解决方案，以学习具有与集中式深度学习解决方案或网络范围优化问题相比显著较低的前传需求的最优功率系数。不同于传统的解决（3.2）或（3.3）的优化方法，这些方法需要知道 \mathbf{a}_k 和 \mathbf{B}_{ki} 的信息，本文展示 LSF 信息可以用于直接计算最优功率的近似值。本文强调，在提出的解决方案中，每个 AP 都有一个唯一的 DNN，其训练基于该 AP 的本地传播环境及其相对于其他 AP 的位置。这与现有的分数功率分配算法形成对比，后者在每个 AP 上应用相同的启发式算法 [10], [12]。图 1 展示了无蜂窝网络架构。分布式 DNN 模型的实施可以在专为机器学习优化的专用硬件上在每个 AP 级别完成，相较于通用处理器更为高效 [40]。

3.2.1 完全分布式 DNN

本节介绍了提出的完全分布式的基于每个 AP 的 DNN 功率分配模型，该模型仅依赖于本地 AP 与不同 UE 之间的信道的局部统计信息，这些信息可以在 AP 上轻松获取。对于给定的 AP 1，本文使用一个全连接的前馈 DNN，将 UE 的 LSF 系数 $\beta_{kl} : \forall k$ 作为输入，以执行功率分配，因为这些参数已经捕捉到了网络中传播信道和干扰的主要特征，并且可以根据接收信号强度在实践中轻松测量得到。因此，对于给定的 AP 位置，本文试图学习局部可用系数 $\beta_{kl} : \forall k$ 和最优传输功率的平方根 $\mu_{kl}^* : \forall k$ 之间的未知映射关系。相比于集中式实现，这样可以降低在 AP 之间交换 LSF 系数的必要性，实现可扩展的网络操作。

输入数据准备：为了简化训练过程，根据现有的领域知识对输入数据进行预处理是至关重要的，这样训练过程可以集中于学习未知的方面。因此，本文采用基于 LSF 系数的启发式功率分配方案来获得输入，而不是将 LSF 系数作为 DNN 的原始输入。本文通过数值发现，所提出的启发式输入提供了更好的动态范围和分布，从而改善了分布式 DNN 的性能。对于给定的样本，从启发式中获得的系数的计算方式类似于 [12]

$$\rho'_{kl} = \sqrt{P_{\max}^{\text{dl}}} \frac{(\beta_{kl})^v}{\sum_{i=1}^K (\beta_{il})^v}, \quad k = 1, \dots, K, \quad (3.10)$$

其中 v 是一个常数指数，用于重新塑造 LSF 系数。请注意，可以直接从启发

表 3-1 完全分布式 DNN 布局。
需要训练的参数: 5,557

Value 1	Size	Parameters	Activation Function
Input	K	-	-
Layer 1 (Dense)	32	672	linear
Layer 2 (Dense)	64	2112	tanh
Layer 3 (Dense)	32	2080	tanh
Layer 4 (Dense)	K+1	693	relu

式方案中获取 LSF 系数之间的比例。这个比例是确定功率分配的主要因素。因此，启发式输入提供了更好的动态范围和分布，而不会丢失信息。然后，使用鲁棒缩放器对启发式系数 $\{\rho'_{kl} : \forall k\}$ 的对数（dB 刻度）进行数据标准化。它使用第一和第三四分位数之间的范围（即四分位距）对数据进行缩放。这样可以减少数据集中由于不同 UE 到给定 AP 的 LSF 系数之间的巨大差异而存在的异常值的影响，特别是在相对较大的覆盖区域中。

提议的 DNN 结构：每个接入点（AP）的完全分布式 DNN 布局如表 3-1 所示。需要注意的是，DNN 不仅试图逼近归一化功率系数，还试图逼近每个 AP 传输的总功率，即（对于 AP 1）： $\sum_{k=1}^K \mu_{kl}^2$ 。本文观察到，将这个约束条件以额外的输出形式添加到网络中可以提高预测功率的准确性。原因是，从 WMMSE 算法得到的 AP 分配功率之和不一定是常数，并且等于最大功率限制 P_{max}^{dl} ，即使对于所有 AP 来说 P_{max}^{dl} 是相同的。实际上，对于大多数模拟的用户设备（UE）位置，给定 AP 的总分配功率小于 P_{max}^{dl} ，也就是说，WMMSE 算法选择减少一些 AP 的功率，以尝试最大化优化目标。这导致输出层的大小为 $K+1$ ，而不是 K 。

3.2.2 有额外信息的分布式 DNN

为了改善基于分布式学习的解决方案的性能，在本节中提出了另一个分布式 DNN 模型。该 DNN 模型利用了无需通过前传链路将信息通信到 AP 的额外信息。

1) 额外信息：分布式解决方案的一个限制因素是缺乏关于给定 UE 与网络中所有 AP 之间的 LSF 系数之间相互关系的信息。基本关系可以通过数据进行隐式学习，但并非所有信息都可以学习到。一个典型的基本关系是 UE 的平均信道增益与此 AP 对 UE 的 SE 的贡献之间的比例。这个贡献是由 NN 被训练来逼近的最大化目标确定的。然而，该 UE 的 SE 表达式不仅受到所有 UE 与该单个 AP 的平均信道增益的影响，还受到 UE 与其他 AP 之间的信道增益的影响。给定 AP 的本地 LSF 系数无法填补这些信息。例如，具有给定 LSF 的 UE 可能位于与考虑的 AP 不

表 3-2 具有额外信息的分布式 DNN 布局。
需要训练的参数：21973

Value 1	Size	Parameters	Activation Function
Input	2K	-	-
Layer 1 (Dense)	64	2624	linear
Layer 2 (Dense)	128	8320	elu
Layer 3 (Dense)	64	8256	tanh
Layer 4 (Dense)	32	2080	tanh
Layer 5 (Dense)	K+1	693	relu

同的角度方向，其中一些角度会使其靠近其他 AP，而另一些角度则不会，从而影响考虑 AP 传输的功率对 UE 的重要性。所提出的 DNN 的额外输入在一定程度上填补了这些缺失的信息，通过提供 AP 的 LSF 系数与网络中所有 AP 的 LSF 系数之间的比率。每个 UE 都有一个这样的比率，可以表示为

$$\rho_{kl}'' = \sqrt{P_{\max}^{\text{dl}}} \frac{(\beta_{kl})^v}{\sum_{l'=1}^L (\beta_{kl'})^v}, \quad k = 1, \dots, K. \quad (3.11)$$

在将附加输入转换为 dB 刻度后，采用鲁棒缩放器对该附加输入进行缩放。为了在每个 AP 上获取这种额外信息而无需前传信令，可以采用以下步骤。首先，根据所有 AP 到特定 UE 的接收信号强度，估计 (3.11) 式的分母在 UE k 上。然后，每个 UE 使用标准控制信令通道向网络中的所有 AP 广播这个单一组合值。由于每个 AP 已经有关于 UE 对自身的 LSF 系数的信息 ((3.11) 式的分子)，因此在前传信令方面，计算额外信息不需要额外的成本。

2) 提议 DNN 的结构：带有额外信息的分布式 DNN 的布局如表 3-2 所示。在这种情况下，输入层由大小为 2K 的向量组成。也就是说，对于每个 UE，每个 AP DNN 有两个输入，分别是 (3.10) 式和 (3.11) 式中所示的输入。可以看出，为了利用 DNN 可用的额外信息，与完全分布式情况相比，采用了更复杂的 DNN 结构。

3.3 聚类 DNN 功率分配

大型无小区网络很可能是分层的，其中不相交的 AP 群集连接到单独的边缘处理器 (EP)，而 EP 又与 CPU 相互连接 (CPU 可以是物理实体或逻辑实体)。该网络架构如表 3-3 所示。在本节中，本文提出了一种利用这种结构的基于学习的功率分配问题的替代解决方案，通过在每个群集中拥有一个联合 DNN 来进行功率分配。考虑的架构与 [41] 中提出的混合云无线接入网络 (H-CRAN) 之间存在联系，该架构示例说明了无小区大规模 MIMO 可以部署在该实际架构之上。

表 3-3 聚集式 DNN 布局。
需要训练的参数：246207

Value 1	Size	Parameters	Activation Function
Input	cK	-	-
Layer 1 (Dense)	128	7808	linear
Layer 2 (Dense)	512	66048	elu
Layer 3 (Dense)	256	131328	tanh
Layer 4 (Dense)	128	32896	tanh
Layer 5 (Dense)	c(K+1)	8127	relu

所提出的群集化 DNN 模型可以在专门为机器学习进行优化的专用硬件上的 EP 上实现，并且相应地，属于给定群集的 AP 的 LSF 系数需要通过前传链路与 EP 进行通信。然而，不需要在不同的群集之间共享 LSF 系数。这是对之前提到的关于给定 UE 与网络中的 AP 之间的 LSF 系数之间相互关系缺乏信息的问题的另一种解决方案。从减少光纤连接长度和部署成本的角度来看，群集化架构比星型拓扑更可取，特别是考虑到从每个群集的 AP 到附近的 EP 的无线前传链路 [41], [42]。此外，边缘计算可以提供具有高数据速率的超低延迟环境，使计算密集型和对延迟敏感的应用程序（如功率分配问题）能够在靠近 UE 的位置执行 [42]。基于群集的 DNN 功率分配在网络中可实现的 SE 和前传/中传要求之间提供了一个折衷方案。同样，由于在训练阶段，群集化的 DNN 利用了网络范围内的总 SE 和 PF 解决方案，因此每个 EP 都使用了一个隐含地利用整个网络结构和传播环境的 DNN。

群集化 DNN 的布局如表 III 所示。每个群集中的 AP 数量用 c 表示。值得一提的是，DNN 的结构取决于所选择的群集大小。所提出的布局是基于 $c=3$ 的数值评估选择的，但它也适用于不同的群集大小，例如 $cK < 128$ 。DNN 的输入是通过将来自属于群集的所有 AP 的 UE 到 AP 的 LSF 系数的 dB 刻度应用于鲁棒缩放器来形成的。群集的 DNN 输出表示群集中所有 AP 到网络中所有 UE 的归一化功率系数，以及群集中每个 AP 的预测总功率。

3.4 训练

本节重点介绍了早前提出的 DNN 模型的训练过程和结构的动机。此外，本文还对在本论文中使用的不同传统和基于学习的算法解决功率分配问题的计算复杂度和运行时要求进行了简要介绍。

3.4.1 DNN 训练

为了训练 DNN, 首先生成一个包含大量训练对 $\{f(\beta_{kl}), \mu_{kl}^* : \forall k, l\}$ 的集合。所有提出的 DNN 模型的训练都是在两个不同的数据集上进行的: 一个使用正交导频信号 ($\tau_p = K$), 另一个使用非正交导频信号 ($\tau_p < K$)。这些数据集是通过使用第 2 章中描述的 WMMSE-ADMM 算法解决优化问题来生成的。本文定义向量 $\bar{\mu}_l^* = [\bar{\mu}_{1l}^*, \dots, \bar{\mu}_{Kl}^*, \Omega_l]^T$, 将 AP 1 到网络中所有 UE 的最优化归一化功率与 AP 分配的总功率 (作为总功率预算的比例表示, 即 $\Omega_l = \frac{\sum_{k=1}^K \mu_{kl}^2}{P_{max}^{dl}}$) 连接起来。在分布式情况下, API 的 DNN 的训练旨在最小化以下损失函数:

$$\text{Loss} = \|\bar{\mu}_l^* - \bar{\mu}_l^{\text{DNN}}\|^2 \quad (3.12)$$

对于群集化 DNN, 假设将给定群集中所有 AP 的最优归一化功率和总分配功率比例到网络中的所有 UE 的相应向量表示为 $\eta^* = [\bar{\mu}_l^*, \dots, \bar{\mu}_{l+c-1}^*]^T$ 。相应地, 群集的 DNN 的损失函数可以写成以下形式:

$$\text{Loss} = \|\eta^* - \eta^{\text{DNN}}\|^2 \quad (3.13)$$

在 (3.12) 和 (3.13) 中描述的损失函数是在训练样本上进行平均, 并且 DNN 分别旨在最小化分布式模型和群集模型的这些损失函数。训练过程包括更新神经元之间的权重以及每一层的偏置。采用 Adam 优化器, 并将学习率设置为 0.001 以确保收敛, 在此之后, 学习率按 10 的倍数进行减小, 以微调权重更新。批量大小和训练轮数通过试错方法选择。

3.4.2 激活函数的选择

虽然本文提出了特定的 DNN 结构, 但值得一提的是, 找到最佳的 DNN 结构和激活函数也可以看作是独立的优化问题, 需要进一步的研究。参考文献 [23] 和 [25], 本文尝试了多种结构和激活函数, 以找到为本文的问题提供最小均方误差 (MSE) 的配置。可以注意到, 所提出的 DNN 在一定程度上遵循类似的结构。在“扩展”层中使用线性和 ELU 激活函数, 其中层的大小从一层增加到下一层, 以强调输入之间的差异。这一点特别重要, 因为每个 AP 到大范围覆盖区域内随机选择的 UE 的 LSF 系数差异很大, 形成了一系列可能的值, 而与这个值范围相比, LSF 系数的很大一部分相对较小。随后, 在逐渐减小层大小以达到所需输出维度时, 使用双曲正切激活函数来平衡线性激活函数产生的梯度, 并避免梯度爆炸问题, 为

DNN 模型提供更稳定性。

3.4.3 复杂度分析

通过分析 WMMSE-ADMM 算法的更新步骤，可以注意到 [9, 公式 (48)] 中的 $L \times L$ 矩阵求逆在计算复杂度方面具有最大的复杂度。这个操作只需要每个问题每个 UE 执行一次，因为相同的逆矩阵可以在后续迭代中使用。因此，WMMSE-ADMM 算法的计算复杂度为 $O(L^3 K)$ [9]。基于学习的方法的计算复杂度主要用于训练 DNN 的数据生成阶段，需要重复解决 (3.2) 或 (3.3) 中的实际优化问题以生成训练数据集。另一方面，对于具有 T 层的 DNN，每个层具有 T_i 个神经元，所需的实际乘法和加法运算量分别为每个层 i 的 $T_i \times T_i - 1$ 。此外，总共需要评估 $\sum_{i=1}^T T_i$ 个激活函数。

在接下来的内容中，完全分布式 DNN 将被称为“DDNN”，带有辅助信息的分布式 DNN 将被称为“DDNN-SI”，而群集化 DNN 将被称为“CDNN”。DNN 模型的估计运行时间明显低于使用 WMMSE-ADMM 算法解决优化问题的传统方法。然而，值得指出的是，在实际实现中很难在处理时间方面进行公平比较。一个重要的原因是实现将基于不同的硬件架构。WMMSE-ADMM 算法非常适合在经典的（多核）CPU 架构上执行，而 DNN 很可能在针对机器学习进行优化的硬件架构上运行，例如神经处理单元（NPU）[23]。尽管如此，当它们在同一硬件上执行时，巨大的运行时间差异仍然具有启示性。在表 3-4 中，本文记录了 WMMSE-ADMM 算法和 DNN 模型的平均运行时间（针对 100 个样本），这些模型适用于之前提出的处理方案和优化目标。可以看到，DNN 模型满足实时处理约束，主要依赖于网络中的调度决策，这些决策可能达到 1 毫秒的数量级，如前面所述。请注意，学习基础解决方案的记录运行时间表示支持整个无小区网络的所有分布式/群集化 DNN 实现所需的总时间，即每个 DNN 的计算时间小于 1 毫秒。显然，CDNN 通过为每个群集中的 AP 提供一个共享的 DNN，提供了最小的（总）计算复杂度。本文使用相同的平台，即 4 核 Intel(R) Core i5-10310U CPU，基本频率为 1.7 GHz，最大睿频频率为 4.4 GHz。所有程序均使用 Python 3.8 编写。

表 3-4 与 WMMSE-ADMM 算法相比，所提出的 DNN 模型的计算时间为毫秒

Algorithm	Sum-SE		PF	
	MR	RZF	MR	RZF
ADMM	88.6	131.7	124.8	163.5
DDNN	8.8	9.2	8.6	9.0
DDNN-SI	9.7	9.8	9.5	9.7
CDNN	3.2	3.2	3.2	3.2

3.5 本章小结

本章对系统的原理进行了详细介绍，包括 sum-SE 和 PF 最大化功率分配方法、分布式 DNN 功率分配模型、聚类 DNN 功率分配模型、训练设置详情

第4章 结果分析

4.1 模拟设置

本文考虑一个由 $L=16$ 个接入点 (AP) 组成的无蜂窝网络, 部署在一个 $1000 \text{ m} \times 1000 \text{ m}$ 的区域内。每个 AP 的天线数为 $N=4$ 。为了模拟一个没有人为边界的大区域, 本文假设采用环绕拓扑结构。此外, 本文假设在感兴趣的区域内随机均匀地放置了 $K=20$ 个用户设备 (UE)。结果是在一个测试数据集上平均得到的, 该数据集由 2000 个 UE 分布组成, 与训练数据集相互独立。本文考虑在总接收机噪声功率为 -94 dBm 的 20 MHz 信道上进行通信。每个 AP 的最大下行传输功率为 $P_{max}^{dl} = 1 \text{ W}$, 而每个 UE 在导频传输阶段的上行功率为 $p_i = 100 \text{ mW}$ 。相干块长度选择为 $\tau_c = 200$ 。在此之后, 术语“正交导频”指的是为所有用户分配唯一的正交导频, 即 $\tau_p = K$, 而“非正交导频”指的是 $\tau_p = 10$ 的情况, 其中利用了第 II-B 节中描述的导频分配算法。生成 LSF 系数的路径损耗模型如 [8], [9] 所示, 其中 d_{kl} 是 UE k 和 AP l 之间的距离。模拟参数总结在表 V 中, 代表了一个城市微蜂窝环境。

$$\beta_{kl} = -30.5 - 36.7 \log_{10} \left(\frac{d_{kl}}{1 \text{ m}} \right) \text{ dB}$$

DNN 模型的训练分别在两个数据集上进行, 用于正交导频和非正交导频的情况, 每个数据集含有 350,000 个样本。通过试错方法选择了 (3.10) 和 (3.11) 中的缩放参数 ν 为 0.6。为了处理 UE 数量的变化, 通常有两种方法来处理基于学习的解决方案: 要么为不同数量的 UE 使用不同的 DNN, 要么训练一个单一的 DNN 来处理可变数量的 UE。

由于分布式/聚类模型的简单性和相对较小的可训练参数数量, 本文建议可以

表 4-1 无蜂窝大规模 MIMO 网络仿真参数

Area of interest (wrap around)	$1000 \text{ m} \times 1000 \text{ m}$
Bandwidth	20 MHz
Number of APs	$L = 16$
Number of UEs	$K = 20$
Number of antennas per AP	$N = 4$
Pathloss exponent	$\alpha = 3.76$
Per-AP maximum DL transmit power	$P_{max}^{dl} = 1 \text{ W}$
UL transmit power	$p_i = 100 \text{ mW}$
UL/DL noise power	-94 dBm
Coherence block length	$\tau_c = 200$
Pilot sequence length	$\tau_p = 10 \text{ or } K$

针对不同的 UE 数量训练一系列不同的 DNN，并将所有 DNN 的最终权重分别存储在 AP 或 EP 上，用于分布式和聚类情况。然后，AP 或 EP 根据系统中当前的 UE 数量选择相应的 DNN 模型。

4.2 Sum-SE 与 PF 最大化

在这个小节中，我复现分析了 Sum-SE 和 PF 最大化目标之间的差异。为此，图 4-1(a) 和 4-1(b) 绘制了使用 WMMSE-ADMM 算法求解 Sum-SE 和 PF 优化问题得到的每个用户的 SE 的累积分布函数 (CDF)，分别使用 MR 和 RZF 预编码。为了进行比较，还在图中显示了使用等功率分配方法得到的 SE。可以看出，在 MR 预编码方案下，两种优化方案之间存在明显的差异。在实施最大化 Sum-SE 方案中，因为模型仅关注最大化 SE，因此一些用户的信道条件太差，为这些用户提供服务，不能得到良好的信噪比，所以他们不幸地被放弃了，用来为其他用户提供更好的服务以最大化 Sum-SE 目标，在这种情况下用户有被剥夺网络资源的可能性，而在最大化 PF 目标方案中，则不会有这种情况，因为该方案的设计目的是试图在最大化 SE 和为覆盖区域内的所有 UE 提供良好服务之间找到合理的权衡；在实验考虑的仿真设置中，使用 RZF 预编码方法时，两种方案之间的性能差异相对较小。这是因为 RZF 预编码方法具有减轻干扰的能力，因此即使对于信道条件最差的 UE，也能提供更好的信噪比。这样的话，Sum-SE 方案就不会放弃掉 (或者放弃掉极少数) 用户，从而为所有 (或大多数) UE 产生非零的功率系数。

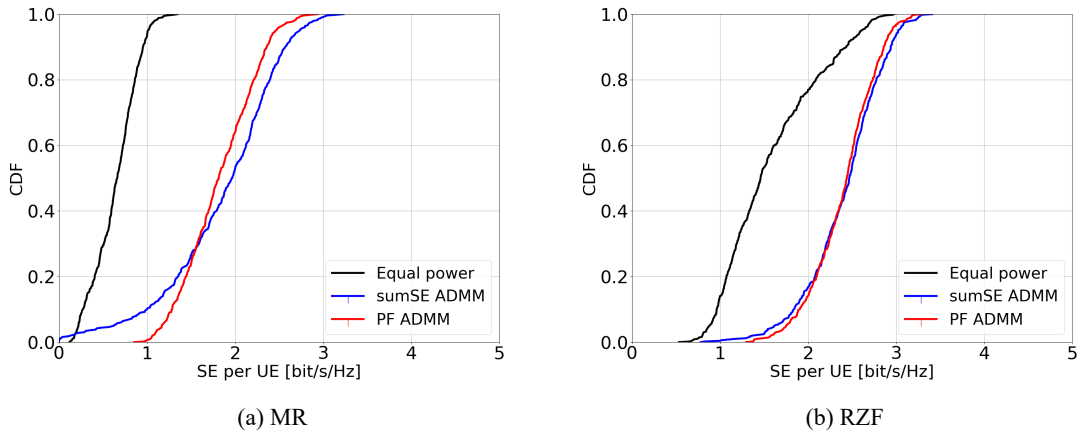


图 4-1 sum-SE 和 PF 最大化目标的每个 UE 的 DL SE 的 CDF

4.3 有额外信息的 DDNN

这个小节复现并对 DDNN-SI 模型与 DDNN 基准情况的性能进行了比较和分析。图 4-2(a) 和图 4-2(b) 分别显示了使用 MR 预编码进行 Sum-SE 和 PF 最大化目标时每个用户的 SE 的累积分布函数 (CDF)。在最大化 Sum-SE 的目标下, 结果显示, DDNN-SI 相对于 ADMM 算法和 DDNN 为不幸的信道条件较差的 UE (即具有低 SE 的 UE) 提供了更好的性能, 但对于信道条件不差的 UE, DDNN-SI 模型提供的性能比 ADMM 略差, 而与 DDNN 相似。在信道条件较差的 UE 处显示出的优势是因为 DDNN-SI 中有每个 AP 输入的额外信息, 如前所述, 提供了关于给定 UE 的 LSF 系数与网络中所有 AP 之间的相互关系的信息。这些信息对于这些不幸的 UE 来说非常关键, 因为它们很可能位于几个 AP 之间, 可能存在多条传播路径, 其中一些路径可能是直射路径, 而其他路径可能经历反射或散射。这导致了信号在传播过程中的多径效应, 使得 UE 接收到的信号中可能包含多个成分, 这些成分对应于不同路径上的信号。由于这些路径相对较近, 它们之间的信道特性可能相似, 包括 LSF 系数。也因此这些 UE 的信道可能受到较大的干扰和噪声影响。因此, DNN 模型利用这些额外信息来区分给定 (单个) LSF 系数对一个 AP 可能意味着的不同角度方向, 并相应地影响 DNN 的输出功率系数。除此之外, 图 4-3(a) 和图 4-3(b) 分别显示了使用 RZF 预编码进行 Sum-SE 和 PF 最大化目标时每个用户的 SE 的累积分布函数 (CDF)。在这种编码方法下, 由于 RZF 编码本身就有减轻干扰的作用, 因此 DDNN-SI 的抗干扰的优势被削减了, 不过尽管如此, 还是可以看出 DDNN-SI 模型的优势相较于 DDNN 模型依然存在, 而相较于 ADMM 算法, DDNN-SI 的优势就消失了。

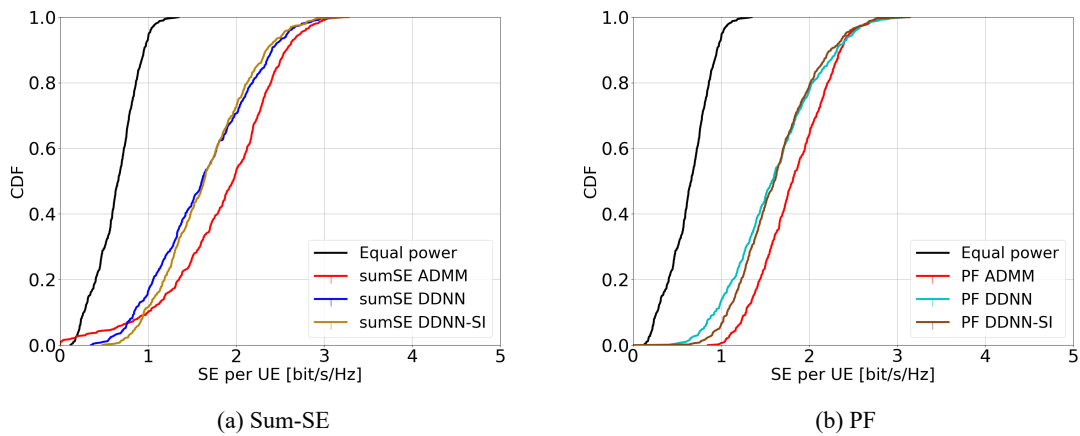


图 4-2 MR 编码处理下每个 UE 的 DL SE 的 CDF。




图 4-3 RZF 编码处理下每个 UE 的 DL SE 的 CDF。

4.4 CDNN

为了解决缺乏各个信道间的 LSF 系数的相互关系这个问题，另一种方法是使用聚类 DNN 模型实现。本节对 CDNN 解决方案进行了复现并与 DDNN 的性能做了比较分析。图 4-4 显示了使用 MR 预编码的 WMMSE-ADMM 基准、DDNN 和 CDNN 解决方案和等功率分配的每个用户的 SE 的累积分布函数（CDF）。可以看到，当以最大化 Sum-SE 为目标时，CDNN 与 DDNN 的性能差别不大，而在信道条件较差的 UE 方面略有优势。而在以最大化 PF 为目标时，CDNN 与 DDNN 的性能也差别不大，在信道条件较差的 UE 方面同样略有优势。两种模型与 ADMM 算法的性能差距依然不小图 4-5 显示了使用 RZF 预编码的 WMMSE-ADMM 基准、DDNN 和 CDNN 解决方案和等功率分配的每个用户的 SE 的累积分布函数（CDF）。可以看到，不管是以最大化 Sum-SE 为目标还是以最大化 PF 为目标，ADMM 算法、DDNN 模型和 CDNN 模型之间的性能差距显而易见。ADMM 的性能高于 CDNN，CDNN 的性能高于 DDNN，

可以看出，对于不幸的 UE，CDNN 的性能与 DDNN 大致相当，但对于具有更好信道条件的 UE，相对于 DDNN，性能下降较小。在图 4-5 中，研究了使用 RZF 预编码的 CDNN 的性能。可以看出，在 RZF 预编码的情况下，CDNN 相对于 DDNN 和 DDNN-SI 模型都有所改善。

从结果中推测，RZF 预编码方案的学习性方法相比于 MR 预编码改进空间更大。前文提到，RZF 预编码方案更加注重减轻干扰，导致功率系数与 LSF 系数输入更密切相关。这就是为什么在 CDNN 实现中将多个 AP 的输入组合到一个 EP 中在这种情况下更有益处的原因。

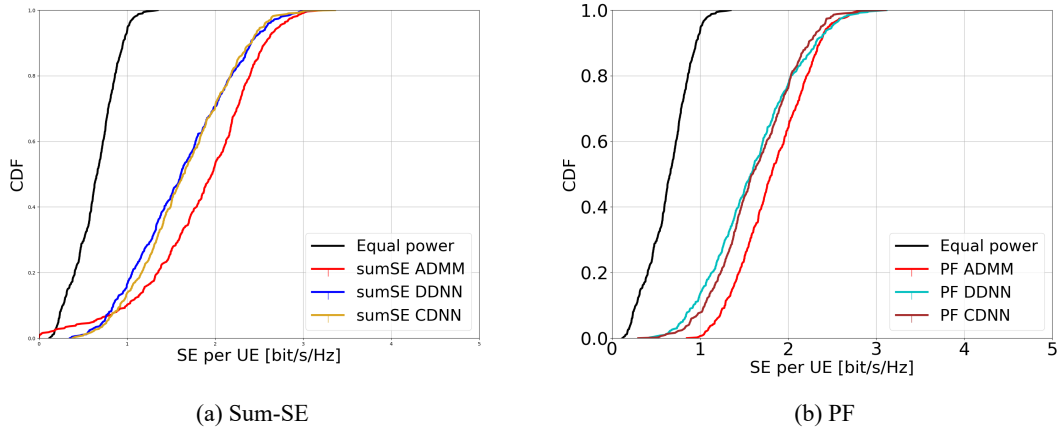


图 4-4 MR 每个 UE 的 DL SE 的 CDF

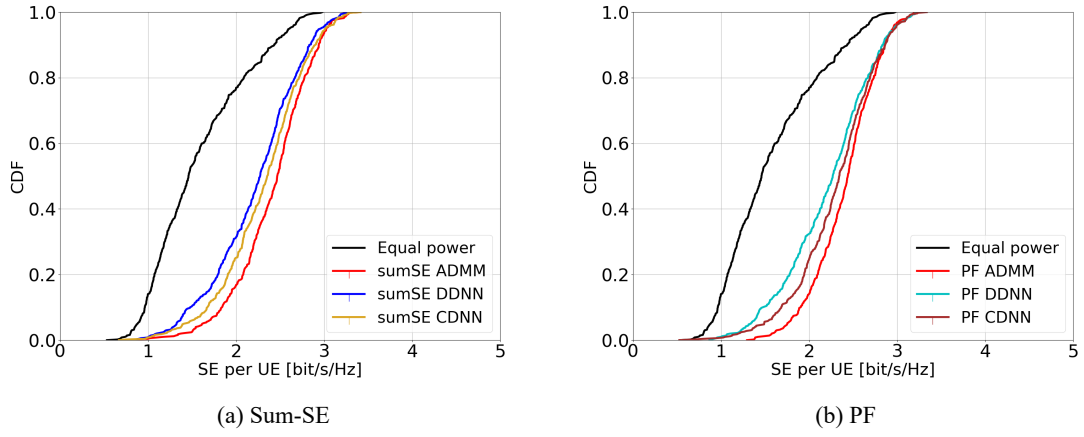


图 4-5 RZF 每个 UE 的 DL SE 的 CDF。

4.5 本章小结

本章对复现实验的结果进行了详细的分析。

第 5 章 总结

5.1 工作总结

本文复现了论文中无蜂窝大规模 MIMO 系统中 DL 的功率分配问题，分别在 MR 和 RZF 预编码方法下进行实验。首先，我对该领域的相关资料进行了充分查询，了解了信道估计、导频分配、下行链路功率分配的概念和公式描述，知晓了 WMMSE 算法作为基准的重要性的具体算法步骤，并在第 2 章中加以概括阐述。在熟悉了基本概念后，我接着精读了几遍论文，了解了论文的研究指标建立在网络范围内的 Sum-SE 和 PF 最大化问题中，论文还利用 WMMSE-ADMM 算法在合理的时间内生成了大量数据，描述了分布式 DNN 算法具体实现方法、聚类 DNN 算法具体实现方法，具体内容在第 3 章中进行了概括阐述。在研读论文的同时，我也同步进行着论文的复现实验，在对照学习下对代码的结构逐渐熟悉了起来。总的来说，论文提出了不同的分布式和聚类 DNN，利用仅在 AP/EP 本地可用的 LSF 系数来逼近功率系数，从而降低了前传/中传需求。在复现论文中，DNN 模型通过一个比传统的 WMMSE-ADMM 算法更小的输入域找到了一个未知的映射，以获得所需的输出功率系数。此外，实验结果显示，基于学习的算法的运行时间远远小于 ADMM 算法，后者是解决功率分配优化问题的最有效的传统方法。减少的前传和计算时间表明论文作者提出的模型在大规模系统中的实施特别有用。数值结果表明，分布式和聚类 DNN 实现对于 WMMSE-ADMM 基准提供了合理的逼近。

5.2 研究展望

在论文中有两个最大化的目标。其中一个在以 Sum-SE 最大化为目标时，会有部分不幸的 UE，他们的信道条件较差，因此通信网络为了得到更高的总频谱效率，会削减对这部分 UE 的网络资源，甚至可能放弃掉这部分 UE，不为它们提供服务，而将服务资源提供给信道条件更好的 UE。在这个过程中，网络没有考虑到实际生活中网络的信道具有最大吞吐量这个限制，因此或许可以在模型中，对模型分配功率的方法进行一些有关最大吞吐量的约束条件，以此来逼近实际生活中的网络功率分配的真实情况。

参考文献

- [1] Marzetta, T. L., Larsson, E. G., Yang, H., Ngo, H. Q. @. Fundamentals of Massive MIMO[M] @. Cambridge : Cambridge University Press @, 2016 @.
- [2] Björnson, E., Hoydis, J., Sanguinetti, L. @. Massive MIMO Networks: Spectral, Energy, and Hardware Efficiency[C] @. Foundations and Trends in Signal Processing @, 11 @, 3-4 @, 154–655 @, 2017 @.
- [3] Björnson, E., Hoydis, J., Sanguinetti, L. @. Massive MIMO Has Unlimited Capacity[J] @. IEEE Transactions on Wireless Communications @, 17 @, 1 @, 574–590 @, 2017 @.
- [4] Nguyen, T. H., Nguyen, T. K., Han, H. D., et al. @. Optimal Power Control and Load Balancing for Uplink Cell-Free Multi-User Massive MIMO[J] @. IEEE Access @, 6 @, 14462–14473 @, 2018 @.
- [5] Ngo, H. Q., Ashikhmin, A., Yang, H., Larsson, E. G., Marzetta, T. L. @. Cell-Free Massive MIMO versus Small Cells[J] @. IEEE Transactions on Wireless Communications @, 16 @, 3 @, 1834–1850 @, 2017 @.
- [6] Zhang, J., Chen, S., Lin, Y., Zheng, J., Ai, B., Hanzo, L. @. Cell-Free Massive MIMO: A New Next-Generation Paradigm[J] @. IEEE Access @, 7 @, 99878–99888 @, 2019 @.
- [7] Buzzi, S., Zappone, A. @. Downlink Power Control in User-Centric and Cell-Free Massive MIMO Wireless Networks[C] @. 2017 IEEE 28th Annual International Symposium on Personal, Indoor, and Mobile Radio Communications (PIMRC) @, 1–6 @, IEEE @, 2017 @.
- [8] Björnson, E., Sanguinetti, L. @. Making Cell-Free Massive MIMO Competitive with MMSE Processing and Centralized Implementation[J] @. IEEE Transactions on Wireless Communications @, 19 @, 1 @, 77–90 @, 2019 @.
- [9] Chakraborty, S., Demir, Ö. T., Björnson, E., Giselsson, P. @. Efficient Downlink Power Allocation Algorithms for Cell-Free Massive MIMO Systems[J] @. IEEE Open Journal of the Communications Society @, 2 @, 168–186 @, 2021 @.
- [10] Demir, Ö. T., Björnson, E., Sanguinetti, L. @. Foundations of User-Centric Cell-Free Massive MIMO[J] @. Foundations and Trends® in Signal Processing @, 14 @, 3-4 @, 162–472 @, 2021 @.
- [11] Ngo, H. Q., Tran, L., Duong, T. Q., Matthaiou, M., Larsson, E. G. @. On the Total Energy Efficiency of Cell-Free Massive MIMO[J] @. IEEE Transactions on Green Communications and Networking @, 2 @, 1 @, 25–39 @, 2018 @.

- [12] Interdonato, G., Frenger, P., Larsson, E. G.@. Scalability Aspects of Cell-Free Massive MIMO[C]@. IEEE International Conference on Communications (ICC)@, 1–6@, IEEE@, 2019@.
- [13] Zhang, J., Björnson, E., Matthaiou, M., Ng, D. W. K., Yang, H., Love, D. J.@. Prospective Multiple Antenna Technologies for Beyond 5G[J]@. IEEE Journal on Selected Areas in Communications@, 38@, 8@, 1637–1660@, 2020@.
- [14] Interdonato, G., Björnson, E., Ngo, H. Q., Frenger, P., Larsson, E. G.@. Ubiquitous Cell-Free Massive MIMO Communications[J]@. EURASIP Journal on Wireless Communications and Networking@, 2019@, 1@, 1–13@, 2019@.
- [15] Burr, A., Bashar, M., Maryopi, D.@. Cooperative Access Networks: Optimum Fronthaul Quantization in Distributed Massive MIMO and Cloud RAN–Invited Paper[C]@. IEEE 87th Vehicular Technology Conference (VTC Spring)@, 1–5@, 2018@.
- [16] Buzzi, S., D’Andrea, C., Zappone, A., D’Elia, C.@. User-Centric 5G Cellular Networks: Resource Allocation and Comparison with the Cell-Free Massive MIMO Approach[J]@. IEEE Transactions on Wireless Communications@, 19@, 2@, 1250–1264@, 2019@.
- [17] Masoumi, H., Emadi, M. J.@. Performance Analysis of Cell-Free Massive MIMO System with Limited Fronthaul Capacity and Hardware Impairments[J]@. IEEE Transactions on Wireless Communications@, 19@, 2@, 1038–1053@, 2019@.
- [18] Bashar, M., Akbari, A., Cumanan, K., Ngo, H. Q., Burr, A. G., Xiao, P., Debbah, M., Kittler, J.@. Exploiting Deep Learning in Limited-Fronthaul Cell-Free Massive MIMO Uplink[J]@. IEEE Journal on Selected Areas in Communications@, 38@, 8@, 1678–1697@, 2020@.
- [19] Femenias, G., Riera-Palou, F.@. Fronthaul-Constrained Cell-Free Massive MIMO with Low Resolution ADCs[J]@. IEEE Access@, 8@, 116195–116215@, 2020@.
- [20] Sarajlić, M., Rusek, F., Sánchez, J. R., Liu, L., Edfors, O.@. Fully Decentralized Approximate Zero-Forcing Precoding for Massive MIMO Systems[J]@. IEEE Wireless Communications Letters@, 8@, 3@, 773–776@, 2019@.
- [21] Jeon, C., Li, K., Cavallaro, J. R., Studer, C.@. Decentralized Equalization with Feedforward Architectures for Massive MU-MIMO[J]@. IEEE Transactions on Signal Processing@, 67@, 17@, 4418–4432@, 2019@.
- [22] Björnson, E., Sanguinetti, L.@. Scalable Cell-Free Massive MIMO Systems[J]@. IEEE Transactions on Communications@, 68@, 7@, 4247–4261@, 2020@.
- [23] Zhao, Y., Niemegeers, I. G., De Groot, S. H.@. Power Allocation in Cell-Free Massive MIMO: A Deep Learning Method[J]@. IEEE Access@, 8@, 87185–87200@, 2020@.

- [24] Nayebi, E., Ashikhmin, A., Marzetta, T. L., Yang, H., Rao, B. D. @. Precoding and Power Optimization in Cell-Free Massive MIMO Systems[J] @. IEEE Transactions on Wireless Communications @, 16 @, 7 @, 4445–4459 @, 2017 @.
- [25] Goodfellow, I., Bengio, Y., Courville, A., Bengio, Y. @. Deep Learning[B] @. MIT Press Cambridge @, 1 @, 2016 @.
- [26] Lee, W., Kim, M., Cho, D.-H. @. Deep Power Control: Transmit Power Control Scheme Based on Convolutional Neural Network[J] @. IEEE Communications Letters @, 22 @, 6 @, 1276–1279 @, 2018 @.
- [27] Sun, H., Chen, X., Shi, Q., Hong, M., Fu, X., Sidiropoulos, N. D. @. Learning to Optimize: Training Deep Neural Networks for Interference Management[J] @. IEEE Transactions on Signal Processing @, 66 @, 20 @, 5438–5453 @, 2018 @.
- [28] Sanguinetti, L., Zappone, A., Debbah, M. @. Deep Learning Power Allocation in Massive MIMO[C] @. 52nd Asilomar Conference on Signals, Systems, and Computers @, 1257–1261 @, 2018 @.
- [29] Chakraborty, S., Björnson, E., Sanguinetti, L. @. Centralized and Distributed Power Allocation for Max-Min Fairness in Cell-Free Massive MIMO[C] @. 53rd Asilomar Conference on Signals, Systems, and Computers @, 576–580 @, 2019 @.
- asdasdasda
- [30] Zhang, C., Patras, P., Haddadi, H. @. Deep Learning in Mobile and Wireless Networking: A Survey[J] @. IEEE Communications Surveys & Tutorials @, 21 @, 3 @, 2224–2287 @, 2019 @.
- [31] Chien, T. V., Canh, T. N., Björnson, E., Larsson, E. G. @. Power Control in Cellular Massive MIMO with Varying User Activity: A Deep Learning Solution[J] @. IEEE Transactions on Wireless Communications @, 19 @, 9 @, 5732–5748 @, 2020 @.
- [32] Nasir, Y. S., Guo, D. @. Multi-Agent Deep Reinforcement Learning for Dynamic Power Allocation in Wireless Networks[J] @. IEEE Journal on Selected Areas in Communications @, 37 @, 10 @, 2239–2250 @, 2019 @.
- [33] Zhang, L., Liang, Y.-C. @. Multi-Agent Deep Reinforcement Learning for Non-Cooperative Power Control in Heterogeneous Networks[C] @. GLOBECOM 2020-2020 IEEE Global Communications Conference @, 1–6 @, IEEE @, 2020 @.
- [34] de Kerret, P., Gesbert, D., Filippone, M. @. Team Deep Neural Networks for Interference Channels[C] @. 2018 IEEE International Conference on Communications Workshops (ICC Workshops) @, 1–6 @, IEEE @, 2018 @.

- [35] Christensen, S. S., Agarwal, R., De Carvalho, E., Cioffi, J. M. @. Weighted Sum-Rate Maximization Using Weighted MMSE for MIMO-BC Beamforming Design[J] @. IEEE Transactions on Wireless Communications @, 7 @, 12 @, 4792–4799 @, 2008 @.
- [36] Shi, Q., Razaviyayn, M., Luo, Z.-Q., He, C. @. An Iteratively Weighted MMSE Approach to Distributed Sum-Utility Maximization for a MIMO Interfering Broadcast Channel[J] @. IEEE Transactions on Signal Processing @, 59 @, 9 @, 4331–4340 @, 2011 @.
- [37] Diamantoulakis, P. D., Karagiannidis, G. K. @. Maximizing Proportional Fairness in Wireless Powered Communications[J] @. IEEE Wireless Communications Letters @, 6 @, 2 @, 202–205 @, 2017 @.
- [38] Chen, L., Ma, L., Xu, Y. @. Proportional Fairness-Based User Pairing and Power Allocation Algorithm for Non-Orthogonal Multiple Access System[J] @. IEEE Access @, 7 @, 19602–19615 @, 2019 @.
- [39] Demir, "O. T., Björnson, E. @. Large-Scale Fading Precoding for Spatially Correlated Rician Fading with Phase Shifts[J] @. arXiv:2006.14267 @.
- [40] Brown, G. @. Cloud-RAN, the Next-Generation Mobile Network Architecture[B] @. Huawei White Paper @, 2017 @. url <https://www-file.huawei.com/-/media/CORPORATE/PDF/mbb/cloudran-the-next-generation-mobile-network-architecture.pdf?la=en>.
- [41] Sriram, A., Masoudi, M., Alabbasi, A., Cavdar, C. @. Joint Functional Splitting and Content Placement for Green Hybrid CRAN[C] @. IEEE 30th Annual International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC) @, 1–7 @, 2019 @.
- [42] Habibi, M. A., Nasimi, M., Han, B., Schotten, H. D. @. A Comprehensive Survey of RAN Architectures Toward 5G Mobile Communication System[J] @. IEEE Access @, 7 @, 70371–70421 @, 2019 @.